

Trabajo Práctico: Amplicon-seq para detección de isoformas con lecturas largas (ONT)

1. Introducción

El objetivo de este trabajo práctico es introducir el uso de **secuenciación de lecturas largas (Oxford Nanopore Technologies, ONT)** aplicada a **cDNA-amplicon-seq** para la detección y caracterización de **isoformas transcriptómicas**.

A diferencia de tecnologías de lecturas cortas (Illumina), las lecturas largas permiten observar directamente combinaciones completas de exones dentro de una misma molécula, lo que resulta clave para:

- Identificar isoformas completas
- Detectar eventos de splicing alternativo
- Distinguir isoformas canónicas de isoformas novedosas

Durante el TP se trabajará con datos reales de ONT correspondientes a amplicones del gen *FMR1*, a partir de dos muestras biológicas (Sample A y Sample B) con un conjunto parcialmente compartido de isoformas. Las muestras fueron tomadas de sangre y células de granulosa ovárica de mujeres.

Contexto: El gen *FMR1* (ENSG00000102081), localizado en el cromosoma X, codifica la proteína **FMRP** y está involucrado en cuatro trastornos genéticos. A través del *splicing alternativo* de su ARNm, el transcripto puede generar numerosas isoformas, lo que sugiere que cada una podría tener un rol celular específico. Con todos sus exones, sin ningún intrón, y desde el sitio de inicio de la traducción y hasta el sitio de *stop*, el mensajero de *FMR1* mide aproximadamente 3,8 kpb. Los *primers* fueron diseñados para hibridar algunos pb río arriba del ATG y algunos pb río abajo del *stop*, por lo que un amplicón del mensajero completo mide un poco más de 3,9 kpb.

En el laboratorio nos interesa la **Insuficiencia ovárica primaria asociada a la fragilidad del X (FXPOI)** y el patrón de expresión de las isoformas en tejido ovárico. En estudios previos, identificamos varias isoformas durante la foliculogénesis en el ovario de rata, pero debido al diseño experimental no pudimos detectar todas las isoformas potencialmente expresadas. De manera similar, no existen estudios en tejidos humanos que describan todas las isoformas expresadas y sus secuencias completas. Por lo tanto, como objetivo, buscamos optimizar la detección de isoformas mediante secuenciación de lecturas largas con tecnología **Oxford Nanopore Technologies (ONT)** en sangre y células de granulosa de mujeres enroladas en un protocolo de ovodonación (no portadoras de la premutación ni la mutación de *FMR1*). Este enfoque permite secuenciar los transcriptos completos con alta sensibilidad, lo que nos brinda la posibilidad de identificar isoformas nuevas.

2. Objetivos del trabajo práctico

Al finalizar el TP, se espera que el/la estudiante sea capaz de:

- Comprender el flujo general de análisis de datos de amplicon-seq con ONT
- Alinear lecturas largas contra un genoma de referencia
- Interpretar métricas básicas de alineamiento
- Inferir isoformas transcriptómicas utilizando el pipeline de **FLAIR**
- Comparar isoformas detectadas entre dos muestras
- Visualizar alineamientos e isoformas en un navegador genómico (IGV)
- Entender por qué las lecturas largas exceden las capacidades de tecnologías de lecturas cortas para este tipo de análisis

3. Organización del directorio de trabajo

La carpeta `/media/libre/datos_genomica/14_TP_RNAseq_largas/Maru/clase-amplicon-seq/` contiene varios archivos. Los que usaremos para el TP son:

```
Homo_sapiens.GRCh38.115.gtf.gz
Homo_sapiens.GRCh38.dna.primary_assembly.fa.gz
sample_A.fastq
sample_B.fastq
```

Sugencia:

Crear carpetas para los *outputs* de cada comando (lo iremos mencionado en cada paso)

4. Archivos de referencia

Genoma

Se utiliza el genoma humano **GRCh38 (Ensembl release 115)**:

- Archivo FASTA: `Homo_sapiens.GRCh38.dna.primary_assembly.fa.gz`

Anotaciones

- Archivo GTF: `Homo_sapiens.GRCh38.115.gtf.gz`

Este archivo contiene las anotaciones génicas y transcriptómicas utilizadas por FLAIR para corregir y colapsar isoformas.

DISCLAIMER:

Control de calidad (QC) de lecturas ONT (paso previo al análisis)

Antes de iniciar cualquier análisis de datos de secuenciación, es fundamental realizar un **control de calidad (Quality Control, QC)** de las lecturas crudas.

En el caso de datos de **Oxford Nanopore Technologies (ONT)**, el QC suele enfocarse principalmente en:

- **Distribución de longitudes de las lecturas**
- **Calidad promedio por lectura (Q-score)**
- Identificación de lecturas truncadas o artefactos

Herramientas comúnmente utilizadas para este paso incluyen, por ejemplo, `NanoPlot`, `NanoQC` o herramientas similares.


Ejemplos de distribuciones de longitudes

A continuación se muestran ejemplos ilustrativos de histogramas de longitudes de lecturas ONT:

Ejemplo 1: muchas lecturas cortas


Este patrón suele indicar:

- fragmentación del cDNA
- problemas en la preparación de la biblioteca
- reads incompletas



Ejemplo 2: lecturas del tamaño esperado

Este patrón es el esperado para un experimento de amplicon-seq bien controlado, donde la mayoría de las lecturas tienen una longitud cercana al tamaño del amplicón.



Filtrado por calidad y longitud

En un pipeline completo, luego del QC se puede aplicar un **filtrado de lecturas**, por ejemplo:

- eliminar lecturas por debajo de un Q-score mínimo
- eliminar lecturas demasiado cortas o demasiado largas respecto al tamaño esperado del amplicón

Este paso permite mejorar la calidad del alineamiento y la detección de isoformas.

Nota para este trabajo práctico

En este TP **no se realizará el paso de QC ni filtrado**, ya que estos conceptos y herramientas fueron abordados previamente en la materia.

Para este ejercicio se trabajará directamente con lecturas ya seleccionadas, con el objetivo de focalizarse en:

- alineamiento contra el genoma
- detección de isoformas
- comparación entre muestras

5. Alineamiento de lecturas contra el genoma

¿Por qué alinear contra el genoma y no contra el transcriptoma?

- Permite detectar isoformas no anotadas
- Evita sesgos introducidos por anotaciones incompletas
- Es un paso necesario para pipelines de detección de isoformas como FLAIR

Indexado del genoma

El indexado del genoma con **minimap2** consiste en generar una estructura de datos que permite acelerar el alineamiento.

```
minimap2 \  
-d Homo_sapiens.GRCh38.dna.primary_assembly.mmi \  
Homo_sapiens.GRCh38.dna.primary_assembly.fa.gz
```

Alineamiento de lecturas

Las lecturas ONT se alinean utilizando parámetros *splice-aware*:

```
minimap2 \  
-ax splice \  
Homo_sapiens.GRCh38.dna.primary_assembly.mmi \  
sample_A.fastq \  
--splice-flank yes \  
-o alineamientos/sample_A.sam
```

Sugerencia: crear la carpeta `alineamientos` y guardar allí los resultados de los alineamientos.

El mismo procedimiento se repite para `sample_B.fastq`.

```
minimap2 \  
-ax splice \  
Homo_sapiens.GRCh38.dna.primary_assembly.mmi \  
sample_B.fastq \  
--splice-flank yes \  
-o alineamientos/sample_B.sam
```

Archivos de salida: `sample_A.sam` y `sample_B.sam`

6. Evaluación del alineamiento

Se utilizan herramientas de **samtools** para evaluar la calidad del alineamiento:

```
samtools flagstat sample_A.sam
```

```
samtools flagstat sample_B.sam
```

Sugerencia: se puede guardar la salida del resumen de la siguiente manera: `samtools flagstat sample_A.sam > flagstat_sample_A.txt`

Este comando resume:

- Número total de lecturas
- Porcentaje de lecturas alineadas
- Lecturas correctamente pareadas (si aplica)

Discutir en clase qué significa cada métrica y qué se espera en datos de amplicon-seq.

7. Conversión y procesamiento de formatos

SAM → BAM ordenado (*sorted*)

```
samtools view -bS sample_A.sam | samtools sort -o sample_A.sorted.bam
```

```
samtools view -bS sample_B.sam | samtools sort -o sample_B.sorted.bam
```

Indexado del BAM

```
samtools index sample_A.sorted.bam
```

```
samtools index sample_B.sorted.bam
```

Conversión a BED12

```
bamToBed -bed12 -i sample_A.sorted.bam > sample_A.bed
```

```
bamToBed -bed12 -i sample_B.sorted.bam > sample_B.bed
```

El formato BED12 es requerido por FLAIR y representa explícitamente la estructura exon–intrón de cada lectura.

8. Detección de isoformas con FLAIR

FLAIR correct

Corrige los alineamientos utilizando anotaciones conocidas:

Como acá vamos a usar el archivo de anotaciones `Homo_sapiens.GRCh38.115.gtf.gz` tenemos que descomprimirlo primero:

```
gunzip Homo_sapiens.GRCh38.115.gtf.gz
```

Y luego podemos correr el comando `flair correct`

```
flair correct \  
--query alinamientos/sample_A.bed \  
--gtf Homo_sapiens.GRCh38.115.gtf \  
--output correct/sample_A
```

```
flair correct \  
--query alinamientos/sample_B.bed \  
--gtf Homo_sapiens.GRCh38.115.gtf \  
--output correct/sample_B
```

Sugerencia: crear la carpeta `correct` y guardar allí los resultados de este paso.

Archivos de salida (no necesariamente devuelve todos): `sample_A_all_corrected.bed`, `sample_A_all_inconsistent.bed`, `sample_A_cannot_verify.bed`, ídem muestra B.

FLAIR collapse

Como tenemos múltiples muestras, concatenamos las lecturas del .bed generadas en el paso anterior (solo las `all corrected`):

```
cat \  
correct/sample_A_all_corrected.bed \  
correct/sample_B_all_corrected.bed \  
> correct/sample_A_B_all_corrected.bed
```

Luego usamos ese archivo .bed para agruparlas en isoformas únicas:

```
flair collapse \  
-g Homo_sapiens.GRCh38.dna.primary_assembly.fa \  
--gtf Homo_sapiens.GRCh38.115.gtf \  
-q correct/sample_A_B_all_corrected.bed \  
-r sample_A.fastq sample_B.fastq \  
--output collapse/sample_A_B \  
--stringent \  
--check_splice \  
--generate_map
```

Sugerencia: crear la carpeta `collapse` y guardar allí los resultados de este paso.

FLAIR quantify

Cuantifica la abundancia de isoformas. Primero necesitamos crear un archivo .tsv (separado por tabulaciones) que contenga la siguiente información: muestra condición batch ruta/a/las/lecturas

Pueden crearlo desde el Notepad o abriendo un archivo de texto con el comando:

```
nano
```

Como en este caso estamos trabajando con las dos muestras juntas, creamos un solo reads_manifest.tsv. Pueden poner el nombre que deseen en muestra, condición y batch, mientras respeten la ruta hacia las lecturas para cada muestra.

```
flair quantify \  
-r reads_manifest_A.tsv \  
-i sample_A.isoforms.fa \  
--isoform_bed sample_A.isoforms.bed
```

Sugerencia: crear la carpeta `quantify` y guardar allí los resultados de este paso.

Archivos de salida: `sample_A_B.isoforms.bed`, `sample_A_B.isoform.read.map.txt`, `sample_A_B.isoforms.fa`, `sample_A_B.isoforms.gtf`, ídem muestra B

9. Visualización en IGV

Los archivos `*.sorted.bam` + `*.bai`, `*.bed` y `*.gtf` pueden cargarse en IGV para:

- Visualizar alineamientos individuales
- Observar estructuras de exones
- Comparar isoformas entre Sample A y Sample B

Para este TP lo haremos online, pero IGV también puede usarse de manera local descargando el programa. Se recomienda navegar a la región del gen *FMR1* y discutir diferencias observadas entre las muestras.

10. Discusión y preguntas

1. ¿Qué isoformas están presentes en ambas muestras?
2. ¿Se detectan isoformas exclusivas de alguna muestra?
3. ¿Qué ventajas ofrece ONT frente a lecturas cortas para este análisis?
4. ¿Qué limitaciones tiene el enfoque de amplicon-seq?

11. Conclusión

Este TP muestra cómo el uso de lecturas largas permite una caracterización más precisa del transcriptoma, destacando el potencial de ONT para estudios de isoformas que no pueden resolverse adecuadamente con tecnologías de lecturas cortas.